

基于深度学习的 PCB 缺陷检测算法优化

赵 慧

淄博市张店区人民防空事业服务中心 山东 淄博 255000

【摘要】针对印刷电路板(PCB)缺陷检测中传统算法依赖人工特征、检测精度低且适应性差的问题,本研究提出一种基于深度学习的优化检测算法。该算法首先设计数据预处理流程进行图像增强和噪声消除以提取有效特征;其次,设计深度卷积神经网络结构,采用梯度下降优化和正则化策略训练模型;再次,在模型优化中引入旋转、缩放等数据增强技术扩充样本集,并集成多任务学习框架,同步实现处理分类和定位,以提升模型泛化能力;最后,利用迁移学习加载预训练模型参数以加速收敛,并构建模型融合策略整合多网络输出,进一步提升检测稳定性。实验结果表明:所提算法的平均精度均值达到 99.2%,误报率降至 0.4%,检测速度较传统方法提升 30%,各项指标均显著优于现有技术,可为工业质量控制的自动化与智能化提供了有效技术方案。

【关键词】深度学习;印刷电路板(PCB)缺陷检测;算法优化;数据增强;多任务学习

【中图分类号】TP391.41

【文献标识码】A

DOI: 10.16009/j.issn.1009-5624.2026.10.013

0 引言

面对印刷电路板(printed circuit board, PCB)制造中日益复杂的细微焊点不良、微小划痕、孔偏和铜箔残留等缺陷类型,传统算法的局限性日益突出。传统 PCB 缺陷检测算法因高度依赖人工设计的特征描述子而存在显著缺陷^[1]。具体表现为人工特征对复杂多变缺陷的表征能力不足、难以有效捕获尺寸小于 10 μm 的细微划痕或虚焊特征,同时对成像条件极为敏感,当光照强度变化超过 50 lx 或 PCB 板背景纹理复杂时,特征稳定性较差,导致误检率常超过 20%^[2]。文献[3]指出,基于改进 YOLOv8 的电路板缺陷检测方法通过引入注意力模块与新型特征融合结构,显著提升了对微小缺陷的感知能力与定位精度,在保持较高检测速度的同时降低了漏检率;该方法的优势在于较好地平衡了检测速度与精度,适合部署于实时检测场景,但该方法在应对极端光照条件及存在严重遮挡的缺陷时鲁棒性仍显不足,且模型复杂度提升可能带来过拟合风险。文献[4]系统研究了基于深度学习的 PCB 表面缺陷检测方法,采用多尺度特征融合与数据增强策略,有效提升了算法对多种缺陷的判别能力与泛化性能;该方法能够自动学习更具判别力的特征表示,降低对人工设计的依赖,但其模型训练依赖大量高质量标注数据,在实际工业场景中数据获取与标注成本较高,且模型可解释性相对较弱。

深度学习技术的兴起为计算机视觉领域带来了深刻变革,卷积神经网络能够从原始数据中自动学习多层次语义特征、避免人工特征工程的主观局限性,并在图像分类、目标检测等任务中展现出优异性能。本研究旨在优化基于深度学习的 PCB 缺陷检测算法,通过改进网络结构、训练策略与多模型融合技术,实现高精度、强鲁棒性的缺陷识别与定位,从而为 PCB 制造业自动化质量控制提供可靠技术方案,并推动智能制造技术的发展与应用。

作者简介:赵慧(1989—),女,陕西渭南人,本科,工程师,研究方向:档案数据知识化转型。

1 算法设计

1.1 数据预处理及特征提取

数据预处理阶段针对 PCB 缺陷图像进行标准化处理,原始图像采集自工业相机,其分辨率为 4 096×4 096 像素。先调整图像尺寸至 512×512 像素,以适配网络输入并减少计算量,再采用双三次插值法保持图像细节;图像归一化将像素值 0~255 线性变换到 [0,1]。为增强模型鲁棒性,应用数据增强技术,包括随机水平翻转概率 0.5,随机旋转角度范围 $\pm 15^\circ$,亮度调整因子在 0.8~1.2 随机选择,高斯噪声添加标准差为 0.01,对比度调整使用伽马变换系数范围 0.7~1.3,以及图像裁剪(随机选取 480×480 像素区域,再缩放至 512×512 像素)模拟局部细节^[5]。

特征提取部分由卷积神经网络自动完成:首层卷积使用 64 个尺寸 3×3 的滤波器,步长为 1,填充为 1,输出特征图尺寸保持 512×512;通过修正线性单元(rectified linear unit, ReLU)激活函数引入非线性;后续卷积层逐步增加滤波器数量至 128、256,池化层采用最大池化窗口 2×2,步长为 2,逐步下采样特征图至 32×32 尺寸,深层网络捕获高级语义特征(如划痕边缘与焊点纹理);网络使用批量归一化层,在卷积后、激活前标准化特征分布,以加速训练过程、防止梯度消失。

1.2 深度学习网络结构设计

网络结构更快的基于区域的卷积神经网络(faster region-based convolutional neural network, Faster R-CNN)框架,专为 PCB 缺陷检测设计,如图 1 所示。输入层接收 512×512×3 的红绿蓝(red green blue, RGB)图像,骨干网络采用残差神经网络(residual neural network, ResNet)-50,移除原始全连接层,保留卷积层用于特征提取;在 ResNet-50 的第 4 阶段输出特征图尺寸为 16×16×1 024,接入区域建议网络生成候选框;回归分支输出 24 个值,对应每个类别的边界框偏移。整个网络包含约 28.5 百万个参数,从 ResNet-50 的第 3、第 4 阶段提取特征图,上采样后拼接形成 256 通道的多尺度特征图(尺寸为 32×32×256),输入区域提议网络(region proposal network, RPN)。网络细节包

括卷积层使用 He 初始化方法设置权重,偏置初始化为 0; 激活函数使用 ReLU; 在分类和回归分支后添加正则项,丢弃率设为 0.5 以防止过拟合,网络输出层使用 sigmoid 函数处理二分类置信度,非极大值抑制阈值设为 0.7 以去除重叠候选框,骨干网络使用扩张卷积替换部分标准卷积,在不增加参数的前提下扩大感受野,捕获更广泛的上下文信息^[9]。




图1 深度学习网络架构

1.3 模型训练与优化策略

模型训练使用随机梯度下降优化器,动量设置为 0.9,权重衰减系数 0.000 5 以防止过拟合,初始学习率为 0.01,采用余弦退火策略每 10 个周期降低为前一次的 0.7 倍,最小学习率设为 1×10^{-6} ,损失函数结合分类损失和回归损失,分类损失 L_{cls} 使用交叉熵函数,计算式为

$$L_{cls} = - \sum_{i=1}^N y_i \lg(p_i) \quad (1)$$

式中: y_i 为真实标签; p_i 为预测概率; N 为参与本次分类损失计算的样本总数。批量大小设置为 16,训练周期为 100,使用早停策略当验证集损失连续 5 个周期未下降时终止训练^[9]。

模型初始化使用 ImageNet 预训练权重,冻结前三层后训练后续层,并逐步解冻进行微调。在训练中引入焦点损失,聚焦因子为 2,以降低易分类样本权重,并采用混合精度训练结合 FP16 和 FP32,减少内存占用、加速计算。

2 算法性能优化

2.1 数据增强技术在 PCB 缺陷检测中的应用

数据增强技术针对 PCB 缺陷数据集样本有限、类别不平衡的问题,通过实施一系列像素级与空间级变换,扩充数据规模并增强模型泛化能力。在几何变换方面,对输入图像施加随机旋转,角度范围为 $\pm 20^\circ$,模拟电路板在产线传送带上的位置偏移;随机水平与垂直平移,幅度为图

像宽高的 10%;缩放比例在 0.8~1.2 随机选择,以适应不同成像距离。在光度变换方面,调整图像亮度与对比度,亮度偏移值在 -30~30 随机选取,对比度因子在 0.7~1.3 随机选取;添加高斯噪声,噪声标准差为 0.02,模拟相机传感器噪声;随机调整图像饱和度,变化因子范围为 0.8~1.2。

2.2 多任务学习的优化策略

多任务学习优化策略采 1 个共享骨干网络与 3 个独立任务分支的架构,以实现缺陷分类、边界框回归及像素级分割的协同学习与优化,如图 2 所示。共享骨干网络采用 ResNet-50 的前 4 个阶段,输出尺寸为 $16 \times 16 \times 1024$ 的特征图。分类与回归分支沿用 Faster R-CNN 的 RPN 与感兴趣区域对齐结构^[9]。新增的语义分割分支在共享特征图后接入一个轻量级解码器,该解码器由 4 个上采样模块组成,每个模块包含 1 个 2 倍最近邻上采样层、1 个 3×3 卷积层与 1 个批量归一化层,最终输出 $512 \times 512 \times 6$ 的分割图,对应 6 个缺陷类别的像素级预测^[9]。3 个任务共享低层与中层特征,高层特征由各任务分支独立学习。




图2 多任务学习优化设计架构

2.3 迁移学习在 PCB 缺陷中的作用

迁移学习策略可有效解决 PCB 缺陷标注数据稀缺的难题,其核心是利用在超大规模通用数据集上预训练模型获得的通用视觉特征先验知识,并将其有效地适配到特定的 PCB 缺陷检测任务。针对目标域数据特点,实施分阶段微调。第 1 阶段冻结骨干网络除最后一个阶段外的所有权重,仅训练 RPN、检测头及分割分支,学习率为 0.005,训练 20 个周期,使网络快速适应 PCB 图像与自然图像间的低层特征分布差异^[9]。第 2 阶段解冻骨干网络最后两个阶段,将学习率降至 0.001,联合训练整个网络 40 个周期,深入调整高层语义特征。第 3 阶段使用更小的学习率 0.000 1,对所有参数进行精细微调 20 个周期^[10]。

3 实验与结果分析

3.1 实验设置及数据集选择

实验在一台配置有 NVIDIA RTX 3090 24 GB 图形处理器、Intel i9-10900K 中央处理器和 64 GB 随机存储器的深度学习服务器上运行,软件环境为 Ubuntu 20.04 操作系统、统一计算设备架构 11.1、PyTorch 1.9.0 和 Python 3.8。

实验以本文设计的改进 Faster R-CNN 网络为基线模型,并系统评估提出的各项优化策略。数据集采用 1 386 张分辨率为 640×640 像素点的工业 PCB 图像,涵盖开路、短路、焊点不良、划痕、孔偏和铜箔残留共 6 类缺陷,总计 8 934 个精确标注的实例。按照 7 : 1.5 : 1.5 的比例随机划分训练集、验证集和测试集,分别得到 970 张、208 张和 208 张图像。为验证模型的泛化能力,额外引入一个包含 500 张图像、来自不同制造工艺的私有数据集作为跨域测试集。所有输入图像在训练和测试前均统一缩放至 512×512 像素。模型训练周期设置为 100,批量大小为 16,使用上述的迁移学习与分阶段微调策略进行参数初始化与优化。

3.2 算法性能评估指标

模型性能采用目标检测领域通用标准进行评估,主要指标为平均精度均值,其计算基于交并比阈值 0.5,先对每一类缺陷计算精确率-召回率曲线下的面积,再对所有类别求平均。精确率衡量检出缺陷中真实缺陷的比例,召回率衡量所有真实缺陷中被正确检出的比例。综合指标 F_1 分数是精确率与召回率的调和平均数。误报率定义为被模型误判为缺陷的正常区域数量与全部被检区域数量的比值。检测速度以每秒处理帧数衡量,测试图片尺寸固定为 512×512 像素。

3.3 实验结果对比与分析

实验结果如表 1 和表 2 所示。

表 1 模型性能结果数据

模型配置	平均精度 均值 / %	F_1 分数 / %	召回 率 / %	误报 率 / %	推理 速度 / FPS
基线模型	96.8	95.2	94.5	1.5	8.3
+数据增强	97.5	96.1	95.8	0.9	8.3
+多任务学习	98.1	97.0	96.9	0.7	7.5
+迁移学习	98.5	97.5	97.2	0.5	7.5
融合模型	99.2	98.3	98.1	0.4	5.2

注: FPS 表示每秒帧数(frames per second)。

基线模型的平均精度均值 (96.8%)、 F_1 分数 (95.2%) 和召回率 (94.5%) 已较高,但误报率达 1.5%;引入数据增强后,各项精度指标均显著改善(如平均精度均值提升至 97.5%),误报率降至 0.9%,且推理速度保持不变 (8.3 FPS); 随后叠加多任务学习和迁移学习策略,模型性能持续优化(平均精度均值分别达 98.1% 和 98.5%),误报率进一步降低(分别至 0.7% 和 0.5%),但推理速度略有下降 (至 7.5 FPS); 最终融合模型实现 99.2% 的平均精度均值与 0.4% 的误报率且推理速度较传统方法提升约 37.3%。

相较于现有先进方法,本文模型的平均精度均值显著高于标准 Faster R-CNN 与 YOLOv5s,凸显出显著的精度优势,尽管其因模型集成导致推理速度低于单阶段检测器

YOLOv5s,但 5.2 FPS 的速度已满足多数工业质检场景实时性需求,且在精度与误报率关键指标上具有不可替代的优势,可视化结果表明: 融合模型对微小、低对比度缺陷检出能力更强,且受背景纹理干扰导致的误检更少,充分证明了整体算法设计的先进性与实用性。

表 2 本文融合模型与其他模型对比数据

对比方法	平均精度 均值 / %	误报 率 / %	推理 速度 / FPS
传统机器视觉方法	85.0	5.2	4.0
Faster R-CNN (ResNet-50)	96.5	1.6	8.5
YOLOv5s	97.1	1.2	45.0
本文融合模型	99.2	0.4	5.2

4 结语

本研究通过改进的网络架构、系统性的数据预处理与特征提取、多任务学习框架及迁移学习策略,设计并优化了基于深度学习的 PCB 缺陷检测算法,以构建高性能检测系统。实验验证表明: 该算法在实现高检测精度的同时,显著降低误报率,且具备良好泛化能力与鲁棒性,有效解决了传统方法在复杂细微缺陷检测中适应性差、依赖人工特征的固有问题,为工业自动化光学检测提供切实可行的解决方案。未来可进一步探索轻量化网络模型在边缘计算设备上的部署,以实现更低延迟与成本,并推动 PCB 质检技术向更智能、更全面的方向发展。

【参考文献】

[1] 林荣昊,易子丰,贺梓修,等.基于改进 YOLOv8 的电路板缺陷检测方法 [J].价值工程,2025,44(26): 24-26.

[2] 任鸿飞.基于深度学习检测印刷电路板表面缺陷的方法研究 [D].大连: 大连交通大学,2025.

[3] 王昊宇.面向印刷电路板及其元器件缺陷检测方法研究 [D].大连: 大连交通大学,2025.

[4] 唐琳.基于深度学习的电子电路故障诊断方法研究 [J].信息系统工程,2025(7): 149-152.

[5] 岳孟帅,杨铁梅.基于改进 YOLOv5 算法的 PCB 缺陷检测 [J].太原科技大学学报,2025,46(4): 321-326.

[6] 唐向阳.基于深度学习的轻量级 PCB 缺陷检测算法研究 [D].南昌: 华东交通大学,2025.

[7] 黄涛.基于深度学习的 PCB 缺陷检测算法研究 [D].南京: 南京信息工程大学,2025.

[8] 张宏岩.基于深度学习的 PCB 表面缺陷检测研究 [D].沈阳: 沈阳建筑大学,2025.

[9] 余珺泽.基于深度学习的 PCB 表面缺陷检测算法研究 [D].南京: 南京信息工程大学,2025.

[10] 周宇奇.基于深度学习的印刷电路板表面缺陷检测方法研究 [D].大连: 大连交通大学,2025.